

IFCE Campus Maracanaú

Disciplina: Redes Neurais Artificiais (RNA)

Professor: Amauri Holanda de Souza

Aluno: Francisco Aldenor Silva Neto

Matrícula: 20221045050117

Relatório de Experimento com Redes Neurais Convolucionais

Introdução

Este relatório tem como objetivo apresentar os resultados de uma série de experimentos realizados com Redes Neurais Convolucionais (CNNs) aplicadas aos datasets **MNIST** e **CIFAR-10**. O principal objetivo foi comparar o desempenho de diferentes configurações de CNN, variando o número de camadas convolucionais e filtros, tanto em termos de **perda** quanto em **acurácia** nos datasets mencionados.

Metodologia

Redes Neurais Convolucionais

Para este experimento, utilizou-se uma arquitetura básica de CNN. As variações incluídas foram:

1. **Número de Camadas Convolucionais:** As CNNs foram configuradas com 2 ou 3 camadas convolucionais.
2. **Número de Filtros:** Utilizou-se CNNs com 32 e 64 filtros em cada camada convolucional.

O modelo foi treinado utilizando a função de perda **Cross Entropy Loss** e o otimizador **Adam**, com uma taxa de aprendizado de 0.001. Os experimentos foram realizados por 10 épocas para cada configuração de modelo.

Datasets

Dois datasets foram utilizados nos experimentos: - **MNIST:** Um dataset de dígitos manuscritos em escala de cinza com imagens de tamanho 28x28 e uma única camada de canal de entrada. - **CIFAR-10:** Um dataset com imagens coloridas de 32x32 distribuídas em 10 classes, com 3 canais de entrada (RGB).

Configurações dos Experimentos

As seguintes configurações foram testadas:

1. **Configuração 1 - MNIST**
 - Camadas convolucionais: 2
 - Filtros: 32
 - Tamanho da imagem: 28x28
 - Canais de entrada: 1
2. **Configuração 2 - MNIST**
 - Camadas convolucionais: 3
 - Filtros: 64
 - Tamanho da imagem: 28x28
 - Canais de entrada: 1
3. **Configuração 3 - CIFAR-10**
 - Camadas convolucionais: 2
 - Filtros: 32
 - Tamanho da imagem: 32x32
 - Canais de entrada: 3
4. **Configuração 4 - CIFAR-10**
 - Camadas convolucionais: 3
 - Filtros: 64
 - Tamanho da imagem: 32x32
 - Canais de entrada: 3

Resultados

Os resultados foram obtidos após o treinamento de 10 épocas para cada configuração. Os gráficos a seguir mostram a curva de perda (**Loss Curve**) para cada configuração, permitindo a comparação visual da convergência dos modelos ao longo das épocas.

Configuração 1: MNIST com 2 camadas convolucionais e 32 filtros

- **Perda ao final da época 10:** 0.0114
- **Acurácia:** 99.03%

Resultados por época:

Época 1: Perda: 0.18385019775198053
Época 2: Perda: 0.060817406763874774
Época 3: Perda: 0.04237998684973462
Época 4: Perda: 0.03360821752620837
Época 5: Perda: 0.0268727101288229
Época 6: Perda: 0.02274255602367854
Época 7: Perda: 0.02003783580401312
Época 8: Perda: 0.01617412261975236
Época 9: Perda: 0.015333169517076901
Época 10: Perda: 0.011384926420859066




Figure 1: Curva de Perda - MNIST com 32 Filtros

Configuração 2: MNIST com 3 camadas convolucionais e 64 filtros

- Perda ao final da época 10: 0.0087
- Acurácia: 99.24%

Resultados por época:

Época 1: Perda: 0.16302646061768933
 Época 2: Perda: 0.04359750169987626
 Época 3: Perda: 0.03021662253295697
 Época 4: Perda: 0.025957261116170922
 Época 5: Perda: 0.019692639852205027
 Época 6: Perda: 0.016182063290179474
 Época 7: Perda: 0.015216261316234169
 Época 8: Perda: 0.012127258742448674
 Época 9: Perda: 0.011224669979324382
 Época 10: Perda: 0.008749728613191794

Configuração 3: CIFAR-10 com 2 camadas convolucionais e 32 filtros

- Perda ao final da época 10: 0.7095
- Acurácia: 69.88%




Figure 2: Curva de Perda - MNIST com 64 Filtros




Figure 3: Curva de Perda - CIFAR-10 com 32 Filtros

Resultados por época:

Época 1: Perda: 1.4181570801741021
Época 2: Perda: 1.0829536960557904
Época 3: Perda: 0.9626900797990887
Época 4: Perda: 0.8980992000045069
Época 5: Perda: 0.847045872522437
Época 6: Perda: 0.8098347007542315
Época 7: Perda: 0.7793136276781102
Época 8: Perda: 0.7537860756411272
Época 9: Perda: 0.7287581711245315
Época 10: Perda: 0.7095023627628756

Configuração 4: CIFAR-10 com 3 camadas convolucionais e 64 filtros

- Perda ao final da época 10: 0.4279
- Acurácia: 75.04%




Figure 4: Curva de Perda - CIFAR-10 com 64 Filtros

Resultados por época:

Época 1: Perda: 1.3795875501449761
Época 2: Perda: 0.9711265486219655
Época 3: Perda: 0.8173393317119545

Época 4: Perda: 0.7201290439690471
Época 5: Perda: 0.6524606653491555
Época 6: Perda: 0.5921993656917606
Época 7: Perda: 0.5457428269221655
Época 8: Perda: 0.5032934140595023
Época 9: Perda: 0.45982771900380054
Época 10: Perda: 0.4279571445206242

Comparação Geral das Curvas de Perda

Para uma melhor comparação entre as diferentes configurações, foi gerado um gráfico combinando as curvas de perda para todas as configurações testadas.




Figure 5: Curva de Perda Combinada

Discussão

Os resultados demonstram um desempenho excelente no dataset **MNIST**, com acurácias superiores a 99% em ambas as configurações testadas. No entanto, o modelo com 3 camadas convolucionais e 64 filtros teve uma leve vantagem, com uma acurácia de **99.24%**, enquanto o modelo com 2 camadas alcançou **99.03%**. Isso sugere que o aumento na complexidade da rede trouxe melhorias, ainda que marginais, para o reconhecimento de dígitos manuscritos.

No caso do dataset **CIFAR-10**, observamos que o desempenho é substancialmente inferior quando comparado ao MNIST, o que pode ser explicado pela maior

complexidade das imagens coloridas em CIFAR-10. No entanto, novamente, o modelo com 3 camadas convolucionais e 64 filtros apresentou melhor desempenho (**73.52%** de acurácia), em comparação ao modelo com 2 camadas e 32 filtros (**69.88%**). A perda também foi menor no modelo mais complexo.

Esses resultados indicam que redes mais profundas e com mais filtros tendem a oferecer melhor desempenho em problemas de classificação de imagens mais complexas, como o CIFAR-10, mas o impacto em datasets mais simples como o MNIST é menos significativo.

Conclusão

Este experimento comparou o desempenho de diferentes arquiteturas de Redes Neurais Convolucionais em dois datasets populares: MNIST e CIFAR-10. Os resultados confirmam que, para problemas mais complexos como o CIFAR-10, o aumento da profundidade da rede e do número de filtros melhora a acurácia. Já para datasets mais simples como o MNIST, essas modificações trazem melhorias mais discretas.

Referências

Repositório do projeto no GitHub: [GitHub Repository](#)